

# Algoritmos para a Detecção de *Drifting* em Sensores de Poços de Petróleo

André Ambrósio Boechat

Departamento de Automação e Sistemas  
Universidade Federal de Santa Catarina

Florianópolis, Agosto de 2012

# Sumário

Introdução

Estrutura de Sistemas de Manutenção CBM

Sistemas de Validação de Sensores

Ensaaios

Dados de Simulação

Dados Reais

Conclusão

# Sumário

## Introdução

## Estrutura de Sistemas de Manutenção CBM

## Sistemas de Validação de Sensores

## Ensaaios

Dados de Simulação

Dados Reais

## Conclusão

## Sensores na Indústria Petrolífera

- Desempenham importantes papéis
  - ações de controle
  - otimização da produção
  - monitoramento do poço
  - monitoramento do desempenho de equipamentos
  - tomada de decisões
- Crescimento do número de sensores
- Localizados em pontos críticos
  - difícil acesso
  - ambientes inóspitos

### Problema

As informações fornecidas pelos sensores são **confiáveis**?


## Drift em Sensores

Desvio lento e contínuo das medições ao longo do tempo

- Um dos problemas mais comuns em sensores
- Difícil detecção
  - comparação com sinais de outros sensores
  - detectável quando os desvios são grosseiros

“Leituras realizadas por um sensor instável ou com desvios excessivos normalmente são mais problemáticas a um operador que a falha completa do sensor.”

(Joseph Eck et al., 1999)



## Proposta do Trabalho

- Estratégia de manutenção **CBM**
- Modelos empíricos baseados em **histórico**

# Sumário

Introdução

Estrutura de Sistemas de Manutenção CBM

Sistemas de Validação de Sensores

Ensaaios

Dados de Simulação

Dados Reais

Conclusão

# Estratégias de Manutenção

CBM (*Condition Based Maintenance*)

Manutenção baseada na condição de funcionamento

## Estratégia tradicional

- Manutenção periódica
- Manutenção reativa

## CBM

- Monitoramento da condição de funcionamento
- Manutenção apenas quando realmente necessário
- Agendamento dinâmico de manutenções
- Planejamento de acordo com as condições
- Redução de manutenções reativas (menos surpresas)



# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos

# Implementação de Sistemas de Manutenção CBM

## Dificuldades

- Grande volume de dados coletados
- Dados provindos de sistemas geograficamente dispersos
- Integração dos dados
- Escalabilidade
- Disponibilidade de conhecimentos especialistas

## Benefícios de uma arquitetura modular e padronizada

- Facilidade de atualização de componentes
- Facilidade para se tornar um fornecedor de soluções
- Redução de preços e custos





# Sumário

Introdução

Estrutura de Sistemas de Manutenção CBM

Sistemas de Validação de Sensores

Ensaaios

Dados de Simulação

Dados Reais

Conclusão

# Avaliação do Desempenho de Sensores

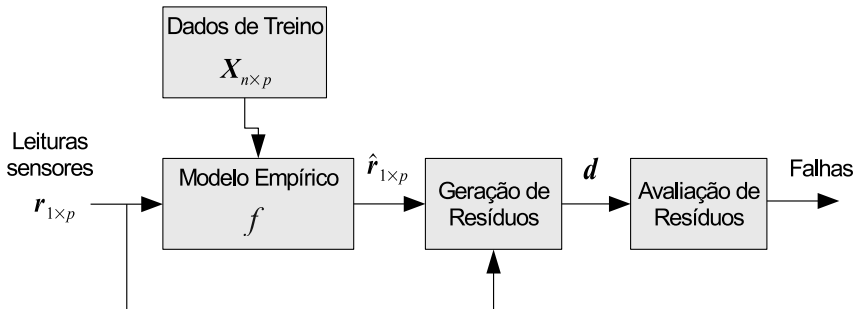
## Abordagem tradicional

- calibração manual periódica
  - não se conhece a real necessidade
  - instrumentos são retirados de operação

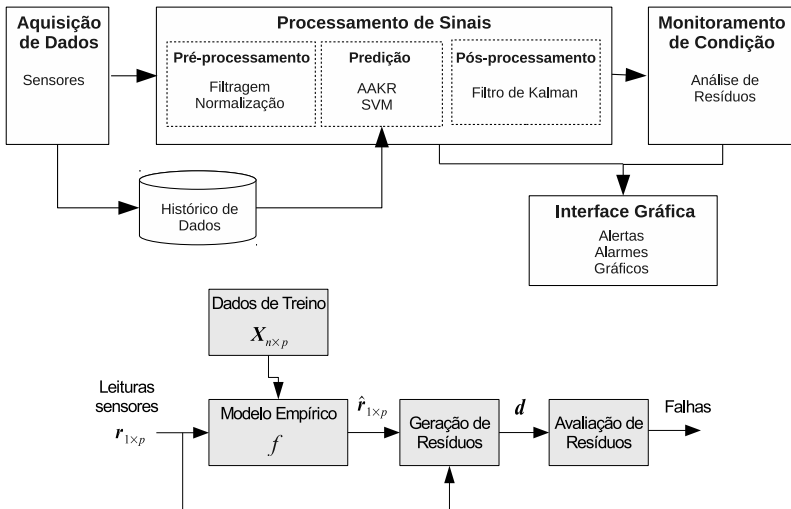
## Manutenção baseada na condição (CBM)

- monitora-se a **condição** de funcionamento
- calibrações físicas apenas quando realmente **necessário**
- tendem a ser menos invasivas e mais eficazes
- redundância por *hardware*
- redundância **analítica**
  - equações fenomenológicas
  - modelos empíricos baseados em **histórico**

# Abordagem por Modelos Baseados em Histórico



# Validação de Sensores e a OSA-CBM



# Predição das Leituras dos Sensores


## AAKR - Regressão por kernel auto-associativa

- Estrutura auto-associativa
- Predições baseadas na similaridade entre as entradas e os vetores de memória
- Dois parâmetros de sintonia: número de vetores ( $n_m$ ) e largura de banda ( $h$ )

## SVM - *Support Vector Machines*



- Estrutura inferencial
- Processo de treinamento constrói uma  $f(\mathbf{r}) \approx y$
- Três parâmetros de sintonia:  $\varepsilon$ ,  $C$  e  $\gamma$

## Auto-associativa × Inferencial



## Geração de Resíduos

- Diferenças entre as leituras dos sensores e as predições dos modelos





# Monitoramento da Condição SPRT

## *Sequential Probability Ratio Test*

- Algoritmo para detecção de propriedades estatísticas
- Testes para verificar qual a distribuição de probabilidade
  - modo normal  $H_0$ : distribuição Normal, média zero e variância semelhante a do ruído
  - modo degradado  $H_1$ : distribuição Normal, média diferente de zero e variância semelhante a do ruído

$$\Lambda^{(i)} = \ln \frac{P(d^{(i)}|H_1)}{P(d^{(i)}|H_0)}$$

- Parâmetro de sintonia  $M$ , diferença tolerável na média

## Filtro de Kalman

Estima continuamente os desvios presentes no sensor

- Considerações:
  - suavidade
  - crescimento lento
  - linear ou exponencial
  - descorrelacionado com desvios de outros sensores

Atualização das estimativas

$$d^{(k)} = d^{(k-1)} + v^{(k)}, \quad v^{(k)} \sim \mathcal{N}(0, \sigma_v)$$


Observação

$$z = d^{(k)} + q^{(k)}, \quad q^{(k)} \sim \mathcal{N}(0, \sigma_q)$$


$$z = r - \hat{r}$$

# Sistemas Implementados


## Sistema 1



## Sistema 2



## Sistema 3



# Sumário

Introdução

Estrutura de Sistemas de Manutenção CBM

Sistemas de Validação de Sensores

**Ensaios**

Dados de Simulação

Dados Reais

Conclusão

## Análises dos Ensaios

- Objetivo  
Verificar a **aplicabilidade** dos sistemas a sensores de poços de petróleo
- Critérios
  - **consistência** e **qualidade** das predições
  - capacidade de **detecção** e **isolamento** de desvios
- Como foram realizados  
Uso de conjuntos de dados compostos por amostras de diferentes **sensores correlacionados**
  - dados gerados por simulação
  - dados reais

## Métricas de Desempenho

- Acurácia ( $E_a$ )

$$E_a = \frac{1}{N} \sum_{i=1}^N \left( \hat{r}^{(i)} - r^{(i)} \right)^2$$

- Erro de predição na ocorrência de desvios ( $E_p$ )
- Auto-sensibilidade ( $S_A$ ) do sensor  $p$


$$S_{A_p} = \frac{1}{N} \sum_{i=1}^N \frac{\left| \hat{r}_{p,drift}^{(i)} - \hat{r}_p^{(i)} \right|}{\left| r_{p,drift}^{(i)} - r_p^{(i)} \right|}$$

- Sensibilidade cruzada ( $S_C$ ) do sensor  $p$  em relação a  $j$

$$S_{C_{p,j}} = \frac{1}{N} \sum_{i=1}^N \frac{\left| \hat{r}_{j,drift}^{(i)} - \hat{r}_j^{(i)} \right|}{\left| r_{p,drift}^{(i)} - r_p^{(i)} \right|}$$


## Descrição dos Dados de Simulação

### Modelo próximo de um poço real



- 4 sensores de pressão:
  - fundo do poço ( $PT_f$ )
  - topo do tubo de produção ( $PT_t$ )
  - topo do anular ( $PT_g$ )
  - a montante do *choke* de injeção ( $PT_m$ )
- Coletado durante 100 horas de produção
- Amostrado em 1 minuto
- Ruído branco de NSR (*noise to signal ratio*) igual a 0.3
- 60 horas como treinamento, 20 de otimização e 20 de teste

# Gráficos dos Dados de Simulação





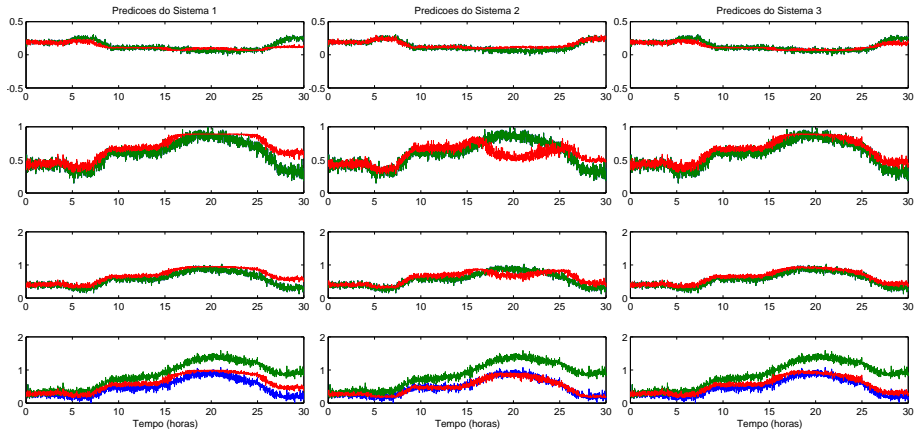
# Indicadores de Desempenho

## Dados de Simulação



	$E_a$	$S_A$	$S_C$	$E_p$
Sistema 1	0.0020	0.2675	0.2682	0.0105
Sistema 2	0.0039		0.3356	0.0139
Sistema 3	0.0023	0.2002	0.1997	0.0046

# Predições para Desvios em $PT_g$

- Predições
- Entradas
- Verdadeiro





# Detecção de Desvios nos Dados de Simulação Sistema 1











# Detecção de Desvios nos Dados de Simulação

## Sistema 2



# Detecção de Desvios nos Dados de Simulação


## Sistema 3



## Descrição dos Dados Reais

- Pressão coletada de 3 sensores
  - no fundo do poço (PDG)
  - na árvore de natal (TPT)
  - a montante do choke de injeção ( $PT_m$ )
- Coletados durante 955 horas de produção
  - 400 primeiras horas para treinamento
  - 100 para otimização
  - 455 para teste
- Amostragem de 1 por minuto

# Gráficos dos Dados Reais



# Indicadores de Desempenho


## Dados Reais

	$E_a$	$S_A$	$S_C$	$E_p$
Sistema 1	0.0035	0.3106	0.2806	0.0078
Sistema 2	0.0069		0.4754	0.0190
Sistema 3	0.0040	0.2418	0.2189	0.0046









# Predições para Desvios no PDG

- Predições
- Entradas
- Verdadeiro









# Detecção de Desvios nos Dados Reais

## Sistema 1









# Detecção de Desvios nos Dados Reais

## Sistema 2



# Detecção de Desvios nos Dados Reais

## Sistema 3



# Sumário

Introdução

Estrutura de Sistemas de Manutenção CBM

Sistemas de Validação de Sensores

Ensaaios

Dados de Simulação

Dados Reais

Conclusão

## Conclusões

- Importância dos sensores na indústria de petróleo
- Problemas de *drifts* ou desvios
- Proposta do trabalho
- Implementação de 3 diferentes sistemas de detecção de desvios
  - Sistema 1: AAKR e SPRT
  - Sistema 2: SVM e SPRT
  - Sistema 3: AAKR, KF e SPRT
- Ensaios
  - simulação  
todos os sistemas detectaram desvios corretamente
  - dados reais  
o Sistema 2 apresentou problemas
  - KF tem uso promissor

## Conclusões

Problemas com a abordagem por modelos baseados em histórico:

- Agrupamento ótimo de sensores
- Seleção dos dados de treinamento
  - livres de falhas
  - cobertura das condições de operação futuras
- Discernir entre mudanças no processo e falhas nos sensores

## Trabalhos Futuros

- Agrupamento automático de sensores
- Validação dos modelos empíricos
- Modelos SVM para predição de séries temporais



# Algoritmos para a Detecção de *Drifting* em Sensores de Poços de Petróleo

André Ambrósio Boechat

Departamento de Automação e Sistemas  
Universidade Federal de Santa Catarina

Florianópolis, Agosto de 2012